


Prédire la Réussite Étudiante à l'Échelle du Big Data

Le défi : construire un pipeline prédictif scalable sur le cloud,
en simulant le traitement de 500 Go de données.



Quel index de performance cet étudiant aura-t-il ?

Une Architecture de Données Moderne sur Google Cloud Platform






Data Lake :
Stockage brut des
données (.csv)

**Moteur de
Traitement :**
Nettoyage,
entraînement du
modèle avec Spark

Data Warehouse :
Stockage des
prédictions et
résultats

BI & Visualisation :
Tableau de bord
décisionnel

Au Cœur du Réacteur : Notre Pipeline Machine Learning sur Spark



Étape 1 : Ingestion & Qualité

- Inférence de schéma
- Normalisation des noms de colonnes (`snake\_case`)
- Vérification des nuls
- Détection des outliers (méthode IQR)

Étape 2 : Ingénierie des Caractéristiques

- `StringIndexer` (conversion "Yes/No" en 0/1)
- `VectorAssembler` (création du vecteur de caractéristiques)

Étape 3 : Modélisation

- Algorithme `Random Forest Regressor` (choisi pour sa robustesse)
- Entraînement sur 80% des données

Étape 4 : Évaluation & Export

- Calcul des métriques sur 20% des données (test)
- Export des résultats vers BigQuery

Le Verdict : Un Modèle d'une Précision Remarquable


$$R^2 = 0.9151$$

Notre modèle explique 91.5% de la variance de l'index de performance.

Erreur Quadratique Moyenne (RMSE) : 5.52

Erreur Absolue Moyenne (MAE) : 4.42

Au-delà de la Prédiction : Quels Sont les Vrais Moteurs de la Réussite ?




Le passé académique et le temps d'étude sont les deux piliers de la réussite. Les autres facteurs ont une influence marginale.

Les Défis du Terrain : Preuve de la Robustesse de la Solution

Défi	Solution
	Noms de champs incompatibles avec BigQuery (ex: `Hours Studied`). Implémentation d'une fonction de nettoyage `snake_case` automatisée à l'ingestion.
	Risque de saturation de la mémoire du nœud maître avec les bibliothèques de visualisation standards. Externalisation complète de la visualisation vers Looker Studio, alimenté par BigQuery.
	Intégration des variables catégorielles ("Yes/No") dans le modèle. Transformation systématique en format binaire (0/1) via `StringIndexer` dans le pipeline.

Du Pipeline au Pilotage : Une Solution Opérationnelle de Bout en Bout

Analyse Décisionnelle



Prédiction en Action

Test sur un nouvel étudiant

🕒 Heures Étudiées: 6

📋 Scores Précédents: 85

🏃 Activités Extra: Yes

🛏 Heures Sommeil: 7

📖 Sujets Pratiqués: 4

**Index de Performance
Prédit : 74.44**

Un Pipeline Fiable, Scalable et Pérenne

PRÉCISION



PRÉCISION

Un modèle performant ($R^2 > 0.91$) qui identifie les leviers fondamentaux de la réussite académique.

SCALABILITÉ



SCALABILITÉ

Une architecture 100% cloud conçue pour traiter des volumes de données massifs sans modification.

PÉRENNITÉ



PÉRENNITÉ

Un pipeline complet sauvegardé sur GCS, garantissant la reproductibilité et prêt pour un déploiement opérationnel.